CVPR Idea

实验Checklist

- [x] ~~11.3-11.4 宇城 baseline riser复现~~
- [x] ~~11.3-11.6 宇城 SelfSelect-GRPO训练~~
- [x] ~~11.6-11.8 宇城 主表填写完毕~~
- [ ] 11.9 宇城 绘制帕累托图
- [ ] 11.10-12 填写表二steering
- [ ] 11.9-11.10 思远 绘制对角线图

主图Checklist

- [x] ~~11.3-11.4 科文 修改图一，提供svg形式~~
- [x] ~~11.4-11.5 宇城 转换图一形式，完成迭代~~
- [x] ~~11.4-11.5 宇城 修改图二提供新版草图或ppt形式~~
- [ ] 11.6-11.12 科文 润色图一图二

写作Checklist

- [x] ~~11.3-11.4 思远 完成相关工作的撰写~~
- [ ] 11.2-11.9 宇城 重写introduction，并写完第一版method
- [ ] 11.10-11.11 宇城 完成其余文字写作
- [ ] 11.12-11.16 ai proof-reading

Multimodal LLMs as Their Own Representation Controller

1. Introduction

1. steering问题简述 2. 概述现有多模态steering 3. 阐述缺陷 4. 人类灵活认知引入self-steering 5. 为了做到self-steering，需要分哪两个环节

图表计算、几何问答和科学图示理解等任务要求多模态大语言模型（MLLM）将视觉文字与符号读取、结构关联以及语言推理衔接起来（Lu et al., 2024）。其中一个环节的错误就可能影响最终答案，例如正确的计算过程仍可能建立在误读的数值之上。激活引导（activation steering）为调节模型的内部计算提供了一种直接途径。以 ActAdd 和对比激活加法（CAA）为代表的方法，通过向隐藏状态注入从对比激活中提取的引导向量，调节模型的后续计算与生成行为（Turner et al., 2023; Rimsky et al., 2024）。

现有研究已将激活引导扩展至多模态场景。ASD 和 DMAS 围绕幻觉相关行为构造引导向量（Su et al., 2025; Yin et al., 2026），SteerVLM 则利用控制提示与视觉上下文实现自适应激活调节（Sivakumar et al., 2025）。与此同时，在语言模型的组合控制研究中，Steer2Adapt 利用少量任务样本搜索可复用引导向量的有效组合（Han et al., 2026）。RISER 则通过任务反馈训练独立路由器，根据输入选择并组合推理引导向量（Ye et al., 2026）。然而，即使系统能够自适应地调整干预，求解模型在控制环节仍主要是干预的接受者，组合决策并未纳入其自身的学习过程。对于需要根据视觉证据与问题需求协调多种功能的 MLLM，这引出了一个核心问题：模型能否根据当前图像与问题，自主选择并组合相关功能表征，从而成为自身内部表征的控制决策者？

神经科学关于认知灵活性的研究为这一问题提供了启发：在灵长类任务切换实验中，不同任务可以复用共享的神经活动子空间，并根据当前需求选择性地调用相关表征（Tafazoli et al., 2026）。受此启发，我们的核心洞察是，将功能表征的选择与组合建模为由 MLLM 自身作出、并通过任务反馈优化的一项中间决策。模型自身的失败经验为识别需要调节的功能提供依据，功能描述及对应的引导向量则为模型提供可理解、可执行的控制选项。然而，语义相关性并不保证组合能够改善求解，不同功能之间的依赖与配合也需要结合具体输入判断。因此，我们将干预后的任务表现作为学习信号，优化模型自身的组合策略，使其逐步建立控制配置与实际求解效果之间的联系，学会为不同输入选择有效的功能表征组合。

基于上述洞察，我们提出 Self-Steering 框架，包含 Self-Weakness Mining（SWM）与 Self-Steering GRPO（SS-GRPO）两个环节。在 SWM 中，从模型自身在多模态数据集上的失败案例进行归因，归纳视觉与文本相关的功能性不足，并据此构建对应的引导向量，形成功能表征库。在 SS-GRPO 中，共享参数的同一 MLLM 承担控制决策与任务求解：模型根据图像、问题及功能描述生成控制配置，执行模块将对应的引导向量组合后注入隐藏状态，再由该模型完成求解。我们以受控求解的答案正确性为奖励，利用 GRPO 的组内相对优势联合优化控制配置与答案的生成策略（Shao et al., 2024）。

本文的主要贡献如下：

- 我们提出 **Self-Steering** 框架，将功能表征的选择与组合建模为 MLLM 自身可学习的中间决策，使模型能够根据当前图像与问题自主生成控制配置，调节内部表征以支持多模态理解与推理。
- 我们提出 **Self-Weakness Mining（SWM）**，从模型自身的失败案例中归纳视觉与文本相关的功能性不足，并据此构建包含功能描述与引导向量的功能表征库，将模型的失败经验转化为可理解、可执行的控制选项。
- 我们设计 **Self-Steering GRPO（SS-GRPO）**，以受控求解的答案正确性为奖励，联合优化同一 MLLM 的控制配置与答案生成，使模型通过实际求解反馈学习适应不同输入的功能表征组合策略。

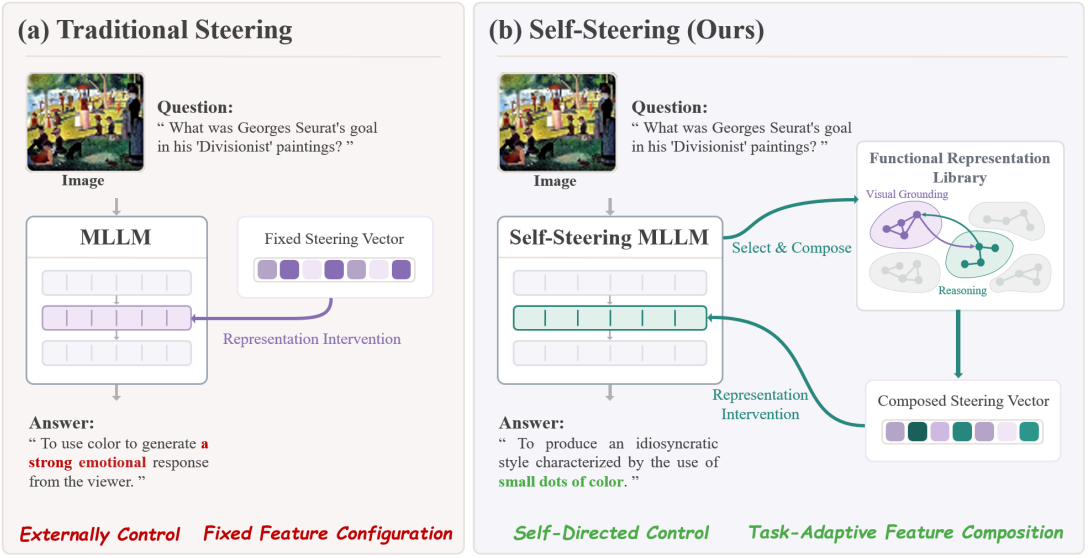


图 1. 传统固定式激活引导与 Self-Steering 的对比。面对同一图像，不同问题可能需要不同的视觉与文本特征组合。(a) 传统固定式引导通过 Fixed 引导向量干预 MLLM 的隐藏状态，难以适应任务需求的差异。(b) Self-Steering 使 MLLM 根据当前图像与问题，从功能表征库中自主选择并组合相关特征，再将对应的引导向量组合后注入自身隐藏状态，由同一模型完成组合决策与受控求解。

2. Related Work

2.1 Activation Steering

激活引导通过干预模型内部表征，为模型行为控制提供了一种轻量化方法。表征工程（Representation Engineering，RepE）探索了神经网络高层表征的提取与操控（Zou et al., 2023），ActAdd 和对比激活加法（Contrastive Activation Addition，CAA）则通过构造不同激活模式之间的差异，获得引导向量，并在推理过程中调节模型行为（Turner et al., 2023; Rimsky et al., 2024）。近期研究进一步将这一范式扩展至多模态大语言模型（MLLM）。Activation Steering Decoding（ASD）通过隐藏状态干预缓解视觉幻觉，SteerVLM 则引入轻量化模块实现自适应激活控制（Su et al., 2025; Sivakumar et al., 2025）。Gan et al.（2026）进一步发现，从纯文本模型中提取的引导向量也能够改善 MLLM 的空间关系理解与计数能力。近期的 Dynamic Multimodal Activation Steering（DMAS）则根据输入语义动态选择视觉感知与真实性相关的干预方向（Yin et al., 2026）。上述研究证明了表征级干预在多模态场景中的有效性，但主要关注特定控制目标或输入条件下的方向选择，对于如何自主组合具有互补功能的内部表征，仍缺乏充分探索。

2.2 Adaptive-Control in MLLMs

为突破固定干预方式的限制，近期研究开始探索自适应激活引导与组合控制。SADI 根据输入语义动态调整激活干预方向（Wang et al., 2025），Steer2Adapt 则利用贝叶斯优化搜索可复用引导向量的有效组合（Han et al., 2026）。K-Steering 进一步通过非线性多标签预测研究多个行为属性的联合控制（Oozeer et al., 2025）。与本文更为接近的是 RISER，该方法构建可复用的推理向量库，并通过强化学习训练额外的轻量级路由器，根据输入选择和组合不同的向量（Ye et al., 2026）。与此同时，CA-TTS 根据模型

置信度动态调度不同推理模块（Du et al., 2026），VisRL 利用强化学习优化视觉关注区域的选择（Chen et al., 2025），AdaReasoner 则通过 Tool-GRPO 优化多模态推理中的工具选择与调用过程（Song et al., 2026）。尽管上述研究已经探索了动态控制及其反馈驱动的优化，但现有方法主要依赖外部路由模块、语义匹配或推理资源调度。与之不同，本文研究由任务求解 MLLM 自身生成面向当前任务的视觉与文本特征组合，并进一步利用下游任务反馈优化其内部特征选择与组合策略。

3. Method

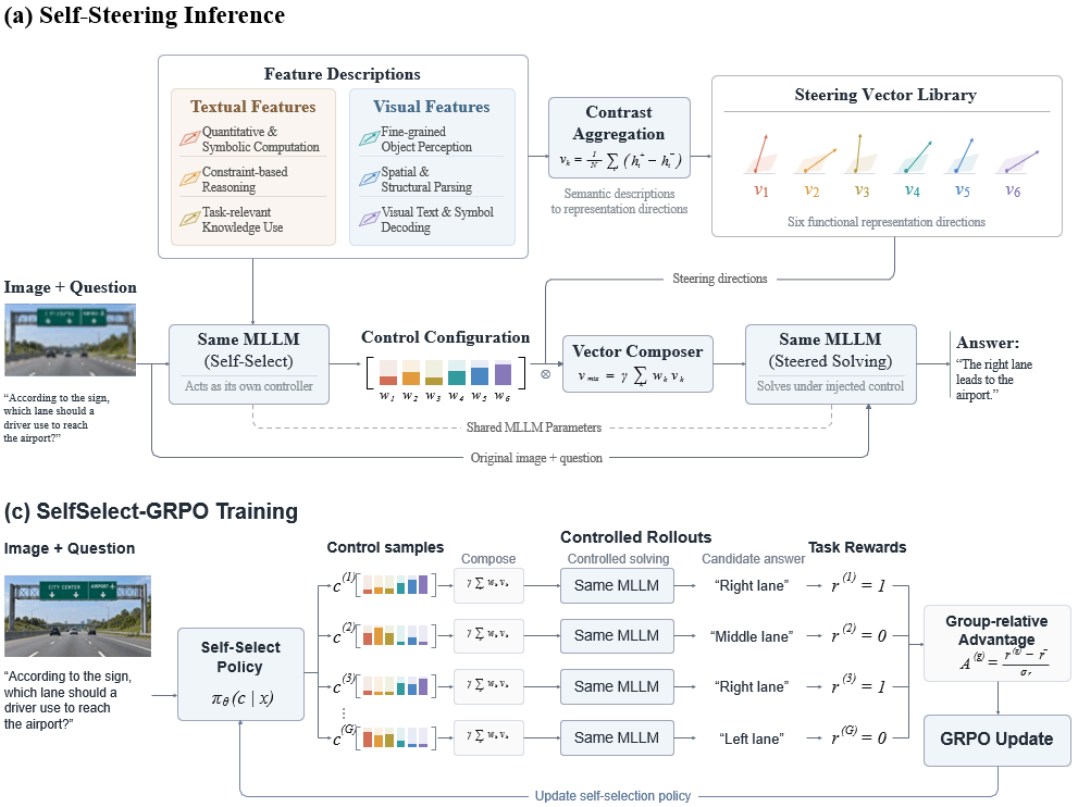


图 2. Self-Steering 与 SelfSelect-GRPO 的整体框架。 (a) **Self-Steering 框架：** 给定图像、问题及预定义特征的语义描述，MLLM 首先根据当前任务需求，从包含三类视觉特征与三类文本特征的 Steering Vector Library 中自主选择并组合相关特征。随后，将选定的 Steering Vectors 组合后注入自身的隐藏状态，由共享参数的同一 MLLM 在内部表征干预下完成任务求解。(b) **SelfSelect-GRPO 训练：** 对于同一输入，MLLM 采样多个候选特征组合，并分别执行对应的受控求解过程。通过计算各候选组合的任务准确性奖励，并利用 GRPO 的组内相对优势优化特征选择策略，使模型逐步学习更有效的任务自适应特征组合。

修改意见：

Self-Weakness Mining（最上面的CAA部分用虚线框指代）

训练和推理阶段融合在一起，就画出GRPO的过程

3.1 Steerable Functional Representation Library

这边先做失败归因。统计出了六类常见错误

Functional Feature Definition.

Contrastive Direction Construction.

3.2 Self-Steering: Task-Conditioned Feature Composition

Self-Selection.

Compositional Steering and Solving.

3.3 SelfSelect-GRPO: Learning to Control from Task Feedback

Grouped Configuration Rollouts and Rewards.

Group-Relative Selection Policy Optimization.

4. Experiment

Main Table

Model/Dataset	Math Reasoning						General V
	Math-Vista			Math-Vision			MMStar
	OE	MC	ALL	OE	MC	ALL	Perceptio
TRAINING-FREE INFERENCE & STEERING							
Qwen3-VL-8B-Ins (Pass@1)	68.4	81.1	75.3	31.8	40.0	35.9	66.6
CAA	69.1	76.7	73.2	24.3	37.9	31.2	65.6
CAST	59.8	70.2	65.4	24.6	14.7	18.4	63.6
TRAINING-BASED MULTIMODAL REASONING							
R1-Onevision	61.7	66.2	64.1	20.8	37.8	29.9	60.8
VL-Rethinker	65.3	81.7	74.1	22.1	39.0	30.7	60.7
OneThinker-8B	68.9	82.4	76.2	38.6	41.6	40.1	66.0
VLM-CapCurriculum	71.7	85.7	79.3	39.9	53.9	46.9	68.2
ADAPTIVE FEATURE CONTROL							
RISER	68.0	80.7	74.9	32.8	39.8	36.3	65.4
Steer2Adapt	69.8	80.7	75.7	32.5	27.4	29.3	66.6
VISTA	68.7	80.7	75.2	35.4	40.1	37.8	66.2
SteerVLM							
OURS							
Self-Steering(w/o SS-GRPO)	69.1	84.1	77.2	36.4	47.5	42.0	67.0
Self-Steering	73.2	87.0	80.7	44.2	57.1	50.7	68.0

帕累托图

Table2

Model/Dataset	Math-Vista	Math-Vision	MMStar	MMMU	Avg
No Steering	75.3	35.9	68.0	58.0	59.3
Best Single Feature					
All Features Activated					
Random Feature Selection					
Textual Features Only					
Visual Features Only					

Self-Steering	80.7	50.7	72.1	67.4	67.7

Figure 3



Figure 4

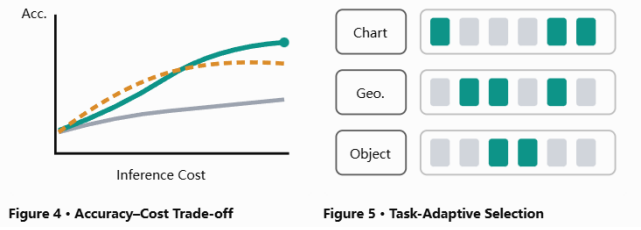


Figure 4 • Accuracy–Cost Trade-off

Figure 5 • Task-Adaptive Selection